

PROJET – LONG SHORT TERM MEMORY

Brent Crude Oil

Présenté par Baptiste DEHAY

I. INTRODUCTION

1.1. Contexte général : volatilité du Brent et intérêt économique/financier

Le Brent Crude Oil constitue l'une des principales références internationales du marché pétrolier. Son prix joue un rôle central dans l'économie mondiale, car il influence à la fois les coûts de production, les prix de l'énergie, les anticipations d'inflation, les décisions d'investissement et les équilibres macroéconomiques des pays importateurs et exportateurs de pétrole. En raison de cette importance, la compréhension et la prévision des dynamiques du Brent représentent un enjeu significatif pour les acteurs financiers, les entreprises du secteur énergétique et les décideurs économiques.

Au-delà du niveau du prix, la volatilité du Brent constitue une dimension essentielle du risque de marché. Elle mesure l'intensité des fluctuations du prix sur une période donnée et permet d'évaluer l'incertitude associée à l'évolution future de l'actif. Une forte volatilité peut traduire des tensions sur l'offre, des chocs de demande, des incertitudes géopolitiques ou encore des phases de stress sur les marchés financiers. À l'inverse, une volatilité plus faible peut être associée à des périodes de stabilité relative.

La prévision de la volatilité est donc un problème central en finance empirique. Elle intervient notamment dans la gestion des risques, la valorisation d'instruments dérivés, l'allocation d'actifs et la mise en place de stratégies de couverture. Dans le cas du Brent, cette tâche est particulièrement complexe, car le marché pétrolier est exposé à des ruptures de régime, à des événements exogènes soudains et à des interactions multiples entre facteurs économiques, financiers et géopolitiques.

1.2. Problématique du projet

Les modèles économétriques de type GARCH constituent une approche classique pour modéliser et prévoir la volatilité des rendements financiers. Leur intérêt principal réside dans leur capacité à représenter l'hétéroscédasticité conditionnelle, c'est-à-dire le fait que la variance des rendements varie au cours du temps. Le modèle GARCH permet notamment de capturer le phénomène de regroupement de la volatilité, selon lequel les périodes de forte volatilité tendent à être suivies par d'autres périodes de forte volatilité.

Toutefois, les modèles GARCH reposent sur une structure paramétrique relativement simple. Cette simplicité est un avantage en termes d'interprétabilité, mais elle peut limiter leur capacité à représenter des dynamiques fortement non linéaires ou des changements de régime complexes. Dans le cas du Brent, dont la volatilité peut être affectée par des chocs macroéconomiques, géopolitiques ou financiers, cette limite constitue un point important.

Les modèles de deep learning, et en particulier les réseaux de neurones récurrents de type LSTM, offrent une alternative intéressante. Les LSTM sont conçus pour traiter des données séquentielles et peuvent apprendre des dépendances temporelles complexes à partir d'un

historique d'observations. Ils peuvent donc, en théorie, capter certains motifs dynamiques que des modèles paramétriques plus simples ne représentent pas explicitement.

La problématique du projet consiste ainsi à déterminer si cette plus grande flexibilité du LSTM se traduit par une amélioration effective de la performance prédictive. Il ne s'agit pas seulement d'appliquer un modèle avancé, mais d'évaluer rigoureusement si ce modèle apporte une valeur ajoutée par rapport à une référence économétrique classique et à une règle naïve de persistance.

1.3. Question de recherche

La question de recherche retenue est la suivante :

Un modèle LSTM permet-il de prévoir plus précisément la volatilité réalisée future à 10 jours du Brent qu'un modèle GARCH(1,1) et qu'une baseline naïve ?

Cette question implique une comparaison empirique entre trois approches. La première est une baseline naïve, qui suppose que la volatilité future est proche de la volatilité récemment observée. La deuxième est un modèle GARCH(1,1), utilisé comme référence économétrique standard pour la modélisation de la volatilité conditionnelle. La troisième est un modèle LSTM, représentant une approche de machine learning séquentiel capable d'exploiter des informations passées organisées sous forme de séquences temporelles.

L'objectif n'est donc pas de démontrer a priori la supériorité du LSTM, mais de tester empiriquement s'il améliore la qualité des prévisions hors échantillon. Une attention particulière sera portée à la comparabilité des modèles : ils devront être évalués sur la même variable cible, sur la même période de test et à l'aide des mêmes métriques d'erreur.

1.4. Présentation rapide de la démarche

La démarche empirique du projet repose d'abord sur la collecte de données journalières du Brent Crude Oil. À partir des prix observés, des rendements logarithmiques journaliers seront calculés. Ces rendements serviront ensuite à construire la variable cible du projet : la volatilité réalisée future à 10 jours, annualisée sur la base de 252 jours de bourse.

Le projet suivra ensuite un protocole de comparaison entre trois modèles. Une baseline naïve sera utilisée comme point de référence minimal. Elle permettra de vérifier si les modèles plus complexes apportent réellement un gain prédictif par rapport à une règle simple fondée sur la persistance de la volatilité. Un modèle GARCH(1,1) sera ensuite estimé afin de fournir une référence économétrique classique. Enfin, un modèle LSTM sera entraîné sur des séquences de variables passées, telles que les rendements, les rendements absolus, les rendements au carré et des mesures de volatilité historique.

Les données seront séparées chronologiquement en échantillons d'apprentissage, de validation et de test. Ce découpage temporel est essentiel afin de reproduire un véritable exercice de prévision et d'éviter toute fuite d'information. Les modèles seront évalués hors échantillon à l'aide de métriques telles que la RMSE et la MAE. Des visualisations permettront également de comparer la volatilité réalisée observée et les prévisions produites par les différents modèles.

1.5. Structure analytique

Dans un premier temps, nous allons chercher à montrer pourquoi la prévision de la volatilité du Brent constitue un sujet pertinent, à la fois sur le plan économique, financier et méthodologique. Cette première étape permettra de situer le projet dans le contexte plus général de la modélisation des risques de marché et de formuler la question de recherche.

Dans un deuxième temps, nous allons présenter les données utilisées et expliquer la construction des variables nécessaires à l'analyse. Nous partirons des prix journaliers du Brent pour calculer les rendements logarithmiques, puis nous construirons la variable cible du projet, à savoir la volatilité réalisée future à 10 jours. Cette étape sera centrale, car elle permettra de définir précisément ce que les modèles chercheront à prévoir et de garantir la cohérence temporelle entre les informations disponibles et la variable prédite.

Dans un troisième temps, nous allons exposer les différentes approches de modélisation retenues. Nous commencerons par une baseline naïve, qui servira de référence minimale. Nous présenterons ensuite le modèle GARCH(1,1), utilisé comme référence économétrique classique pour la prévision de la volatilité. Enfin, nous introduirons le modèle LSTM, dont l'objectif sera d'exploiter des séquences de données passées afin d'identifier d'éventuelles dépendances temporelles plus complexes.

Dans un quatrième temps, nous allons préciser le protocole expérimental mis en place pour comparer ces modèles de manière rigoureuse. Nous détaillerons notamment le découpage temporel des données, les règles de normalisation, l'organisation des séquences pour le LSTM, ainsi que les métriques d'évaluation retenues. L'objectif sera de vérifier que la comparaison repose sur un véritable exercice de prévision hors échantillon, sans fuite d'information.

Dans un cinquième temps, nous analyserons les résultats empiriques obtenus. Nous comparerons les performances de la baseline naïve, du modèle GARCH(1,1) et du modèle LSTM à partir d'indicateurs quantitatifs et de visualisations graphiques. Cette analyse permettra d'observer si le LSTM apporte effectivement une amélioration prédictive, ou si les modèles plus simples restent compétitifs.

Enfin, nous discuterons la portée des résultats. Nous chercherons à identifier les limites du protocole, les risques de surapprentissage, les contraintes liées aux données utilisées et les conditions dans lesquelles les conclusions peuvent être interprétées. La conclusion synthétisera les principaux enseignements du projet et proposera des pistes d'amélioration pour prolonger l'analyse.

II. DONNEES ET CONSTRUCTION DES VARIABLES

2.1. Présentation du Brent Crude Oil

Le Brent Crude Oil est l'une des principales références internationales du marché du pétrole brut. Il sert de prix de référence pour une part importante des transactions pétrolières mondiales, notamment en Europe, en Afrique et au Moyen-Orient. Son évolution est suivie de près par les acteurs financiers, les entreprises du secteur énergétique, les institutions économiques et les décideurs publics.

Le choix du Brent se justifie par son importance économique et par la richesse de ses dynamiques de marché. Son prix est influencé par de nombreux facteurs, tels que les anticipations de demande mondiale, les décisions de production, les tensions géopolitiques, les variations du dollar, les conditions macroéconomiques globales et les comportements spéculatifs sur les marchés financiers. Ces éléments contribuent à produire des épisodes de forte instabilité, ce qui rend la modélisation de sa volatilité particulièrement pertinente.

Dans ce projet, le Brent est étudié non pas à travers le niveau de son prix, mais à travers ses variations journalières et la volatilité qui en découle. L'objectif est de construire une variable de volatilité réalisée future, puis d'évaluer dans quelle mesure différents modèles peuvent l'anticiper à partir de l'information passée.

2.2. Source des données : BZ=F, Yahoo Finance

Les données utilisées dans ce projet proviennent de Yahoo Finance, à partir du ticker BZ=F, qui correspond aux contrats futures sur le Brent Crude Oil. Cette source présente l'avantage d'être facilement accessible, reproductible et directement exploitable dans un environnement Python.

L'utilisation du ticker BZ=F permet de récupérer une série journalière comprenant notamment les prix d'ouverture, les plus hauts, les plus bas, les prix de clôture, les prix de clôture ajustés lorsque disponibles, ainsi que les volumes échangés. Dans le cadre de ce projet, l'analyse se concentre sur les prix de clôture, car ils constituent une référence couramment utilisée pour calculer les rendements journaliers.

Le recours à une source publique et identifiable contribue à la reproductibilité du projet. Le notebook associé au rapport devra permettre de télécharger ou de charger les mêmes données, afin qu'un lecteur puisse reproduire les étapes de calcul, d'estimation et d'évaluation des modèles.

2.3. Période d'étude et fréquence des données

Les données sont utilisées à fréquence journalière. Cette fréquence est adaptée à l'objectif du projet, car elle permet de disposer d'un nombre suffisant d'observations pour estimer les modèles et entraîner le LSTM, tout en conservant une interprétation financière claire des variations de prix.

La période d'étude retenue doit couvrir une fenêtre suffisamment longue pour inclure plusieurs régimes de marché. Une période allant de 2005 à 2024 est appropriée, car elle permet d'observer des phases de stabilité relative ainsi que plusieurs épisodes de forte volatilité, notamment autour des crises financières, des chocs pétroliers, de la période Covid-19 ou encore des tensions géopolitiques récentes.

Ce choix temporel vise à éviter que les modèles soient évalués uniquement sur une période trop spécifique. Une série longue permet d'exposer les modèles à des configurations de marché variées, ce qui est important pour analyser leur capacité à généraliser hors échantillon. La période effectivement retenue après nettoyage des données devra être indiquée précisément dans le rapport.

2.4. Prix utilisés : prix de clôture journalier

La variable de départ du projet est le prix journalier du Brent, noté P_t . Les données utilisées proviennent d'un fichier historique issu de la plateforme Investing.com. Ce fichier contient les colonnes Date, Price, Open, High, Low, Vol. et Change %.

Dans ce projet, la colonne Price est retenue comme prix journalier de référence. Elle correspond au prix de clôture, ou au dernier prix disponible de la séance, pour les contrats futures sur le Brent. La base de données disponible ne contenant pas de colonne explicitement nommée Close ou Adj Close, la colonne Price est utilisée de manière cohérente dans l'ensemble de l'analyse.

La série de prix utilisée sera donc notée :

$$P_t$$

Où P_t désigne le prix du Brent à la date t . Cette série constitue la base du calcul des rendements logarithmiques journaliers, puis de la construction des mesures de volatilité passée et future.

2.5. Calcul des rendements logarithmiques

Les prix bruts ne sont pas directement utilisés pour la modélisation de la volatilité. En effet, les séries de prix financiers présentent généralement des tendances, des changements de niveau et des propriétés de non-stationnarité. Il est donc préférable de travailler sur les rendements, qui décrivent les variations relatives du prix d'une période à l'autre.

Les rendements logarithmiques journaliers sont calculés de la manière suivante :

$$r_t = \ln(P_t) - \ln(P_{t-1})$$

où r_t désigne le rendement logarithmique du Brent entre les dates $t - 1$ et t , P_t le prix observé à la date t , et P_{t-1} le prix observé à la date précédente.

Les rendements logarithmiques présentent plusieurs avantages. Ils permettent de mesurer les variations relatives du prix, ils sont additifs dans le temps et ils sont généralement plus adaptés à l'analyse statistique que les prix en niveau. Dans ce projet, ils constituent la variable de base à partir de laquelle seront construites les mesures de volatilité passée et future.

Après le calcul des rendements, la première observation de la série est nécessairement perdue, car elle ne dispose pas d'un prix précédent permettant de calculer r_t . Les éventuelles valeurs manquantes restantes doivent être supprimées ou traitées avant la construction des variables de volatilité.

2.6. Construction de la volatilité réalisée future à 10 jours

La variable cible du projet est la volatilité réalisée future à 10 jours. Elle mesure l'intensité des variations du prix du Brent sur les dix jours suivant une date donnée. Pour une date t , elle est construite à partir des rendements logarithmiques futurs observés entre $t + 1$ et $t + 10$.

La volatilité réalisée future à 10 jours est définie comme suit :

$$RV_{t,t+10} = \sqrt{252 \times \frac{1}{10} \sum_{i=1}^{10} r_{t+i}^2}$$

où $RV_{t,t+10}$ désigne la volatilité réalisée future sur l'horizon de dix jours, r_{t+i} représente le rendement logarithmique observé i jours après la date t , et le facteur 252 permet d'annualiser la mesure sur la base d'environ 252 jours de bourse par an.

Cette variable est la grandeur que les modèles cherchent à prédire. Elle est commune à la baseline naïve, au modèle GARCH(1,1) et au modèle LSTM. Son choix permet d'évaluer les modèles sur un horizon court, mais suffisamment long pour lisser une partie du bruit journalier.

Il est essentiel de souligner que cette volatilité réalisée future n'est connue qu'après la date t . Elle ne doit donc jamais être utilisée comme variable explicative. Elle intervient uniquement comme cible lors de l'apprentissage supervisé du LSTM et comme variable observée lors de l'évaluation des prévisions.

2.7. Construction des variables explicatives

Les variables explicatives sont construites uniquement à partir d'informations disponibles jusqu'à la date t . Elles ont pour objectif de fournir aux modèles, en particulier au LSTM, des informations sur la dynamique récente des rendements et de la volatilité.

La première variable explicative est le rendement logarithmique journalier r_t . Il renseigne sur la variation récente du prix du Brent. Son signe indique le sens de la variation, tandis que son amplitude donne une première indication sur l'intensité du mouvement de marché.

La deuxième variable est le rendement absolu, défini par :

$$|r_t|$$

Cette variable mesure l'ampleur du mouvement journalier indépendamment de sa direction. Elle est pertinente pour la prévision de la volatilité, car une forte variation positive ou négative peut signaler une augmentation de l'incertitude.

La troisième variable est le rendement au carré, défini par :

$$r_t^2$$

Cette variable est directement liée à la variance. Elle est également cohérente avec la logique du modèle GARCH, dans lequel la variance conditionnelle dépend du carré des innovations passées.

Une autre variable explicative importante est la volatilité réalisée passée à 10 jours, définie par :

$$RV_{t-10,t} = \sqrt{252 \times \frac{1}{10} \sum_{i=0}^9 r_{t-i}^2}$$

Cette variable synthétise le niveau de volatilité observé sur les dix derniers jours disponibles. Elle sera utilisée comme variable explicative du LSTM, mais également comme fondement de la baseline naïve de persistance.

Enfin, une volatilité réalisée passée sur une fenêtre plus longue, par exemple 20 ou 30 jours, pourra être ajoutée. Elle permet de capter un régime de volatilité plus persistant et moins sensible aux variations très récentes. Par exemple, la volatilité passée à 20 jours peut être définie par :

$$RV_{t-20,t} = \sqrt{252 \times \frac{1}{10} \sum_{i=0}^{19} r_{t-i}^2}$$

L'ensemble de ces variables permettra au LSTM d'exploiter des séquences temporelles contenant à la fois des informations sur les rendements récents, leur amplitude et le niveau historique de volatilité.

2.8. Principe de cohérence temporelle et absence de fuite d'information

Un principe méthodologique central du projet est le respect de la cohérence temporelle. Pour une prévision effectuée à la date t , seules les informations disponibles jusqu'à cette date peuvent être utilisées comme variables explicatives. La variable cible, en revanche, correspond à la volatilité réalisée entre $t + 1$ et $t + 10$, c'est-à-dire à une information future qui ne sera connue qu'a posteriori.

Cette distinction est essentielle pour éviter toute fuite d'information. Une fuite d'information se produit lorsqu'un modèle utilise, directement ou indirectement, des données futures pour produire une prévision. Dans ce cas, les performances mesurées seraient artificiellement améliorées et ne refléteraient pas la capacité réelle du modèle à prévoir la volatilité hors échantillon.

Dans ce projet, cette contrainte sera respectée à plusieurs niveaux. Les variables explicatives seront construites exclusivement à partir des rendements passés ou contemporains. La normalisation des données du LSTM sera ajustée uniquement sur l'échantillon d'apprentissage, puis appliquée aux échantillons de validation et de test. Enfin, le découpage des données respectera strictement l'ordre chronologique, sans mélange aléatoire des observations.

Ainsi, la comparaison entre la baseline naïve, le modèle GARCH(1,1) et le modèle LSTM reposera sur un protocole cohérent : tous les modèles chercheront à prédire la même variable cible, à partir d'informations disponibles au même moment, et seront évalués sur la même

période de test. Cette organisation est indispensable pour garantir la validité méthodologique des résultats obtenus.

III. METHODOLOGIE

3.1. Baseline naïve

3.1.1. Définition

La première approche utilisée est une baseline naïve de persistance. Elle repose sur une hypothèse simple : la volatilité future du Brent sera proche de la volatilité récemment observée. Autrement dit, pour prévoir la volatilité réalisée future à 10 jours, on utilise la volatilité réalisée passée à 10 jours.

La prévision naïve est donc définie de la manière suivante :

$$\widehat{RV}_{t,t+10}^{naive} = RV_{t-10,t}$$

où $\widehat{RV}_{t,t+10}^{naive}$ désigne la prévision naïve de la volatilité future entre $t + 1$ et $t + 10$, et $RV_{t-10,t}$ désigne la volatilité réalisée sur les dix derniers jours disponibles à la date t .

Cette approche ne nécessite aucun apprentissage statistique ni estimation de paramètres. Elle consiste simplement à prolonger dans le futur le niveau de volatilité observé récemment.

3.1.2. Justification

L'utilisation d'une baseline naïve est essentielle dans un projet de prévision. Elle permet de vérifier si les modèles plus sophistiqués apportent réellement une valeur ajoutée. Dans le cas de la volatilité financière, cette baseline est particulièrement pertinente, car la volatilité présente souvent une certaine persistance : les périodes de forte volatilité tendent à être suivies par d'autres périodes de forte volatilité, et les périodes calmes tendent également à persister.

Ainsi, même si la baseline naïve est très simple, elle peut produire des prévisions compétitives. Elle constitue donc un seuil minimal de performance que les modèles GARCH et LSTM doivent dépasser pour être considérés comme réellement utiles.

Son intérêt méthodologique est également important. Si un modèle complexe comme le LSTM ne parvient pas à améliorer significativement les performances par rapport à cette baseline, cela signifie que sa complexité n'est pas nécessairement justifiée dans le cadre du protocole retenu.

3.1.3. Rôle dans la comparaison

La baseline naïve joue le rôle de référence minimale dans l'évaluation empirique. Elle permet de replacer les performances du GARCH et du LSTM dans un cadre interprétable. Une

amélioration par rapport à cette baseline indique que le modèle exploite une information supplémentaire ou une structure dynamique que la simple persistance ne capture pas.

Dans le tableau final des résultats, la baseline sera donc présentée aux côtés du modèle GARCH(1,1) et du modèle LSTM. Les mêmes métriques d'évaluation, notamment la RMSE et la MAE, seront calculées pour les trois approches sur la même période de test. Cette condition est indispensable pour garantir une comparaison équitable.

3.2. Modèle GARCH(1,1)

3.2.1. Présentation du modèle

Le modèle GARCH, pour *Generalized Autoregressive Conditional Heteroskedasticity*, est une approche économétrique largement utilisée pour modéliser la volatilité des séries financières. Il repose sur l'idée que la variance conditionnelle des rendements n'est pas constante dans le temps, mais dépend de l'information passée.

Dans le cadre de ce projet, le modèle GARCH(1,1) est utilisé comme référence économétrique. Il permet de modéliser la dynamique de la volatilité conditionnelle du Brent à partir des rendements passés. Ce choix est justifié par la présence fréquente d'hétéroscédasticité dans les séries financières : les rendements peuvent présenter des périodes de faible variance alternant avec des périodes de variance élevée.

Le modèle GARCH(1,1) est volontairement simple. Il ne cherche pas à intégrer un grand nombre de paramètres, mais à fournir une base robuste et interprétable pour la prévision de la volatilité. Il servira donc de benchmark intermédiaire entre la baseline naïve et le modèle LSTM.

3.2.2. Équation du GARCH(1,1)

Le modèle GARCH(1,1) repose sur deux équations principales. La première décrit le rendement comme une innovation conditionnelle :

$$r_t = \mu + \varepsilon_t$$

avec :

$$\varepsilon_t = \sigma_t z_t$$

où r_t désigne le rendement logarithmique à la date t , μ la moyenne conditionnelle, ε_t l'innovation du modèle, σ_t l'écart-type conditionnel, et z_t un bruit standardisé.

La seconde équation décrit la dynamique de la variance conditionnelle :

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

où ω , α et β sont les paramètres du modèle. Le paramètre α mesure la réaction de la volatilité aux chocs récents, tandis que le paramètre β mesure la persistance de la volatilité dans le temps.

Pour que le modèle soit bien défini, on impose généralement :

$$\omega > 0, \quad \alpha \geq 0, \quad \beta \geq 0$$

Une condition souvent examinée est la somme $\alpha + \beta$, qui donne une indication sur la persistance de la volatilité. Une valeur proche de 1 signifie que les chocs de volatilité mettent du temps à se dissiper.

3.2.3. Estimation sur les rendements

Le modèle GARCH(1,1) sera estimé à partir des rendements logarithmiques journaliers du Brent. Afin d'éviter toute fuite d'information, l'estimation sera réalisée uniquement sur l'échantillon d'apprentissage. Les observations appartenant aux échantillons de validation et de test ne devront pas être utilisées pour ajuster les paramètres du modèle.

Les rendements pourront être exprimés en pourcentage pour faciliter l'estimation numérique. Cette transformation ne change pas la logique du modèle, mais elle impose de veiller ensuite à l'unité des prévisions produites. Si les rendements sont multipliés par 100 lors de l'estimation, les prévisions de volatilité devront être ramenées à l'échelle appropriée avant d'être comparées à la volatilité réalisée cible.

L'estimation permettra d'obtenir les paramètres ω , α et β , ainsi que la variance conditionnelle implicite. Ces éléments serviront ensuite à produire des prévisions de volatilité hors échantillon.

3.2.4. Prévision de la volatilité à 10 jours

La cible du projet étant une volatilité réalisée future à 10 jours, les prévisions du modèle GARCH doivent être converties dans un format comparable. Il ne serait pas méthodologiquement correct de comparer directement une prévision de volatilité conditionnelle à un jour avec une volatilité réalisée sur dix jours.

Pour obtenir une prévision GARCH comparable à la cible, nous allons agréger les variances conditionnelles prévues sur les dix jours futurs. La prévision de volatilité à 10 jours peut alors être écrite sous la forme :

$$\widehat{RV}_{t,t+10}^{naive} = \sqrt{252 \times \frac{1}{10} \sum_{h=1}^{10} \hat{\sigma}_{t+h|t}^2}$$

où $\hat{\sigma}_{t+h|t}^2$ désigne la variance conditionnelle prévue pour l'horizon h , à partir de l'information disponible à la date t .

Cette transformation permet d'obtenir une prévision annualisée, construite sur le même horizon que la volatilité réalisée future. Elle garantit donc une comparaison plus rigoureuse entre le modèle GARCH, la baseline naïve et le modèle LSTM.

3.2.5. Limites attendues du modèle

Malgré son intérêt, le modèle GARCH(1,1) présente plusieurs limites. Sa structure paramétrique est relativement simple : la variance conditionnelle dépend uniquement du carré du choc précédent et de la variance passée. Cette simplicité facilite l'interprétation, mais peut limiter la capacité du modèle à représenter des dynamiques plus complexes.

Dans le cas du Brent, cette limite est importante. Le marché pétrolier peut être affecté par des ruptures de régime, des chocs géopolitiques, des changements soudains de demande ou d'offre, ainsi que par des épisodes de stress financier. Un modèle GARCH standard peut capturer la persistance de la volatilité, mais il ne modélise pas explicitement ces facteurs externes.

Enfin, les performances du GARCH peuvent dépendre des hypothèses faites sur la distribution des innovations. Une distribution normale peut être trop restrictive si les rendements présentent des queues épaisses. Une distribution de Student peut éventuellement être envisagée comme extension, mais le modèle principal restera le GARCH(1,1) standard afin de conserver une référence simple et interprétable.

3.3. Modèle LSTM

3.3.1. Justification du choix du LSTM

Le modèle LSTM, pour *Long Short-Term Memory*, est un type de réseau de neurones récurrent conçu pour traiter des données séquentielles. Contrairement à un modèle statique, il peut recevoir en entrée une succession d'observations passées et apprendre des relations temporelles entre elles.

Son utilisation dans ce projet est motivée par la nature temporelle des données financières. La volatilité du Brent peut dépendre non seulement du rendement observé à une date donnée, mais aussi de la trajectoire récente des rendements et de la volatilité. Le LSTM permet donc de fournir au modèle une fenêtre d'historique, par exemple les trente derniers jours, afin qu'il apprenne à associer certaines séquences passées à un niveau futur de volatilité.

Le choix du LSTM ne signifie pas que ce modèle sera nécessairement supérieur au GARCH. Il est retenu comme approche plus flexible, capable de représenter des relations potentiellement non linéaires. L'objectif du projet est précisément de vérifier empiriquement si cette flexibilité se traduit par une amélioration de la qualité prédictive.

3.3.2. Organisation des données en séquences

Pour entraîner le LSTM, les données doivent être organisées sous forme de séquences temporelles. À chaque date t , le modèle reçoit une fenêtre d'observations passées se terminant à t . Cette fenêtre contient les valeurs successives des variables explicatives sur les jours précédents.

Par exemple, avec une longueur de séquence de 30 jours, l'entrée associée à la date t contient les observations allant de $t - 29$ à t . La cible associée reste la volatilité réalisée future à 10 jours, c'est-à-dire $RV_{t,t+10}$.

Cette organisation permet au LSTM d'apprendre à partir de trajectoires récentes plutôt qu'à partir d'observations isolées. Elle est particulièrement adaptée à la prévision de volatilité, car celle-ci dépend souvent de l'accumulation de mouvements passés et du régime récent du marché.

Il est important que les séquences soient construites séparément sur les échantillons d'apprentissage, de validation et de test, afin de respecter le découpage temporel du projet. Chaque séquence utilisée pour produire une prévision à la date t ne doit contenir aucune information postérieure à t .

3.3.3. Variables d'entrée

Les variables d'entrée du LSTM seront construites à partir des rendements passés et de mesures de volatilité historique. Les variables principales retenues sont les suivantes :

$$r_t, |r_t|, r_t^2, RV_{t-10,t}, RV_{t-20,t}$$

Le rendement logarithmique r_t fournit une information sur la variation journalière du prix du Brent. Le rendement absolu $|r_t|$ mesure l'intensité de cette variation indépendamment de son signe. Le rendement au carré r_t^2 représente une mesure locale de variance. La volatilité réalisée passée à 10 jours $RV_{t-10,t}$ synthétise le niveau récent de volatilité, tandis que la volatilité réalisée passée à 20 jours $RV_{t-20,t}$ capture une information plus lissée sur le régime de volatilité.

Ces variables ont été choisies car elles sont directement liées à la dynamique de la volatilité et parce qu'elles peuvent être construites sans utiliser d'information future. Elles constituent donc un ensemble de variables cohérent avec l'objectif prédictif du projet.

3.3.4. Architecture retenue

L'architecture du LSTM sera volontairement simple afin de limiter le risque de surapprentissage et de conserver une interprétation claire du protocole. Le modèle comprendra une couche LSTM, suivie d'une couche de régularisation de type dropout, puis d'une couche dense produisant une sortie scalaire.

La sortie du réseau correspondra à la prévision de la volatilité réalisée future à 10 jours. Le modèle sera donc formulé comme un problème de régression supervisée.

Une architecture de référence pourra être la suivante :

Entrée : séquence de 30 jours $\times$ nombre de variables explicatives

Couche LSTM : 64 unités

Dropout : 0,2

Couche dense : 1 neurone

Sortie : volatilité réalisée future à 10 jours

La fonction de perte utilisée sera l'erreur quadratique moyenne, car elle est adaptée aux problèmes de régression. L'optimiseur Adam pourra être utilisé pour l'entraînement du réseau.

Cette architecture n'a pas vocation à être excessivement complexe. Dans un projet de comparaison méthodologique, il est préférable de retenir un modèle suffisamment flexible pour apprendre des dépendances temporelles, mais pas au point de rendre les résultats difficiles à interpréter ou fortement dépendants d'un grand nombre d'hyperparamètres.

3.3.5. Normalisation des données

La normalisation des variables est une étape importante pour l'entraînement du LSTM. Les réseaux de neurones sont sensibles à l'échelle des variables : des variables exprimées dans des unités très différentes peuvent ralentir l'apprentissage ou conduire à une optimisation instable.

Les variables explicatives seront donc standardisées avant l'entraînement. Toutefois, afin d'éviter toute fuite d'information, le calcul des moyennes et des écarts-types utilisés pour la normalisation devra être effectué uniquement sur l'échantillon d'apprentissage. Les mêmes paramètres de normalisation seront ensuite appliqués aux échantillons de validation et de test.

Le même principe s'applique si la variable cible est elle-même standardisée. Le scaler utilisé pour la cible devra être ajusté exclusivement sur les valeurs de l'échantillon d'apprentissage, puis appliqué aux autres échantillons. Les prédictions finales du LSTM devront ensuite être transformées inversement afin d'être comparées à la volatilité réalisée dans son unité d'origine.

Cette règle est essentielle. Si la normalisation était effectuée sur l'ensemble des données, elle incorporerait indirectement de l'information provenant du futur, ce qui biaiserait l'évaluation des performances.

3.3.6. Régularisation et early stopping

Le LSTM étant un modèle plus flexible que le GARCH, il présente un risque de surapprentissage. Ce risque apparaît lorsque le modèle apprend trop précisément les particularités de l'échantillon d'apprentissage, au détriment de sa capacité à généraliser sur des données nouvelles.

Pour limiter ce risque, plusieurs précautions seront mises en place. D'abord, l'architecture du réseau restera simple. Ensuite, une couche de dropout sera utilisée afin de réduire la dépendance du modèle à certains neurones pendant l'apprentissage. Enfin, une stratégie d'early stopping sera appliquée à partir de l'erreur observée sur l'échantillon de validation.

L'early stopping consiste à interrompre l'entraînement lorsque la performance sur les données de validation cesse de s'améliorer. Cette méthode permet d'éviter de poursuivre l'apprentissage jusqu'à un point où le modèle commence à suradapter les données d'entraînement.

Ces choix visent à rendre l'évaluation du LSTM plus fiable et à réduire le risque que de bonnes performances apparentes soient dues à un ajustement excessif aux données historiques.

3.3.7. Risques de surapprentissage

Le risque de surapprentissage constitue l'une des principales limites du LSTM dans ce projet. Contrairement à la baseline naïve et au modèle GARCH, le LSTM possède un nombre plus élevé de paramètres et peut apprendre des relations complexes, y compris des relations spécifiques à la période d'apprentissage qui ne se reproduisent pas ensuite.

Ce risque est particulièrement important dans les séries financières, car les dynamiques de marché ne sont pas parfaitement stables dans le temps. Un modèle entraîné sur une période donnée peut mal se généraliser si les conditions de marché changent fortement. Dans le cas du Brent, les ruptures de régime, les chocs exogènes et les épisodes géopolitiques peuvent modifier rapidement la structure de la volatilité.

Pour cette raison, les résultats du LSTM devront être interprétés avec prudence. Une meilleure performance sur la période de test ne suffira pas nécessairement à démontrer une supériorité générale du modèle. Elle indiquera seulement que, dans le cadre du protocole retenu et sur la période étudiée, le LSTM a produit des prévisions plus ou moins précises que les modèles de référence.

La comparaison avec la baseline naïve et le GARCH est donc indispensable pour replacer les performances du LSTM dans un cadre d'évaluation rigoureux.

IV. PROTOCOLE EXPERIMENTAL

4.1. Découpage temporel train / validation / test

Les données utilisées dans ce projet sont des séries temporelles financières. Pour cette raison, le découpage des observations doit respecter l'ordre chronologique. Contrairement à certains problèmes classiques de machine learning, il ne serait pas approprié d'utiliser un découpage aléatoire des observations, car cela reviendrait à mélanger le passé et le futur.

Nous allons donc diviser les données en trois sous-échantillons successifs : un échantillon d'apprentissage, un échantillon de validation et un échantillon de test. L'échantillon d'apprentissage servira à estimer les paramètres des modèles. L'échantillon de validation sera principalement utilisé pour le réglage du modèle LSTM, notamment pour surveiller la performance hors apprentissage pendant l'entraînement. Enfin, l'échantillon de test sera réservé à l'évaluation finale des performances prédictives.

Un découpage possible est le suivant :

Train : 70 % des premières observations

Validation : 15 % des observations suivantes

Test : 15 % des dernières observations

Ce découpage permet de conserver la logique temporelle du problème : les modèles sont entraînés sur le passé, éventuellement ajustés sur une période intermédiaire, puis évalués sur

une période future. Le jeu de test ne doit pas être utilisé pour choisir les hyperparamètres, modifier l'architecture du LSTM ou sélectionner le meilleur modèle. Il doit représenter une véritable période hors échantillon.

Dans le notebook, les dates exactes correspondant aux trois sous-échantillons seront affichées afin de rendre le protocole transparent et reproductible.

4.2. Règles de normalisation

La normalisation concerne principalement le modèle LSTM, car les réseaux de neurones sont sensibles à l'échelle des variables d'entrée. Les variables explicatives peuvent avoir des ordres de grandeur différents : les rendements, les rendements au carré et les mesures de volatilité ne sont pas nécessairement exprimés sur la même échelle. Une standardisation permet donc de faciliter l'apprentissage du réseau.

Cependant, cette étape doit être réalisée avec une grande prudence. Pour éviter toute fuite d'information, les paramètres de normalisation, comme la moyenne et l'écart-type, doivent être calculés uniquement sur l'échantillon d'apprentissage. Ces mêmes paramètres sont ensuite appliqués aux échantillons de validation et de test.

Autrement dit, nous allons ajuster le scaler sur le train, puis transformer les trois sous-échantillons à l'aide de ce scaler. Cette règle empêche le modèle d'utiliser indirectement des informations provenant de périodes futures.

Le même principe s'applique si la variable cible est normalisée. Dans ce cas, le scaler de la cible doit lui aussi être ajusté uniquement sur l'échantillon d'apprentissage. Après la prédiction, les valeurs prédites devront être ramenées à leur échelle d'origine afin de pouvoir être comparées à la volatilité réalisée observée.

Cette étape est importante, car une normalisation effectuée sur l'ensemble des données introduirait une information issue du test dans le processus d'apprentissage et conduirait à une évaluation trop optimiste des performances.

4.3. Horizon de prévision

L'horizon de prévision retenu dans ce projet est de 10 jours. Plus précisément, à chaque date t , les modèles cherchent à prévoir la volatilité réalisée sur les dix jours suivants, c'est-à-dire entre $t + 1$ et $t + 10$.

La variable cible est donc définie par :

$$RV_{t,t+10} = \sqrt{252 \times \frac{1}{10} \sum_{i=1}^{10} r_{t+i}^2}$$

Cet horizon présente un intérêt méthodologique. Il est suffisamment court pour rester proche de la dynamique récente du marché, mais il permet aussi de lisser une partie du bruit quotidien présent dans les rendements financiers. Il constitue donc un compromis entre une prévision très

court terme, potentiellement instable, et une prévision plus longue, plus difficile à anticiper à partir des seules informations passées.

L'ensemble des modèles doit être adapté à cet horizon. La baseline naïve utilisera la volatilité réalisée passée sur une fenêtre comparable. Le modèle GARCH devra produire une prévision agrégée sur 10 jours, et non une simple prévision de volatilité à un jour. Le LSTM sera entraîné directement à prédire la volatilité réalisée future à 10 jours.

Le respect de cet horizon commun est indispensable pour garantir que les performances des modèles sont comparables.

4.4. Alignement des dates entre les modèles

L'alignement des dates constitue un point technique mais fondamental du protocole. Les différents modèles ne produisent pas nécessairement des prévisions disponibles sur exactement le même nombre d'observations. Par exemple, la construction des séquences LSTM entraîne la perte des premières observations de chaque échantillon, car le modèle a besoin d'un historique suffisant pour former une séquence complète. De même, le calcul des volatilités passées et futures entraîne la suppression de certaines observations au début et à la fin de la série.

Pour éviter une comparaison biaisée, les performances des modèles seront calculées uniquement sur les dates communes pour lesquelles les trois prévisions sont disponibles. Autrement dit, la baseline naïve, le GARCH et le LSTM devront être évalués sur le même sous-ensemble de dates de test.

Cette règle est importante. Si un modèle était évalué sur une période différente des autres, les métriques obtenues pourraient refléter les caractéristiques spécifiques de cette période plutôt que la qualité intrinsèque du modèle. Par exemple, une période de forte volatilité peut mécaniquement produire des erreurs plus élevées qu'une période calme.

Nous allons donc construire un tableau final de résultats indexé par date, contenant pour chaque date de test :

$$RV_{t,t+10}, \widehat{RV}_{t,t+10}^{naive}, \widehat{RV}_{t,t+10}^{GARCH}, \widehat{RV}_{t,t+10}^{LSTM}$$

Les métriques d'évaluation seront ensuite calculées à partir de ce tableau commun.

4.5. Métriques d'évaluation : RMSE, MAE et QLIKE

Les performances prédictives seront évaluées à l'aide de métriques d'erreur calculées entre la volatilité réalisée observée et la volatilité prédite par chaque modèle.

La première métrique utilisée est la RMSE, ou racine de l'erreur quadratique moyenne :

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^N (RV_t - \widehat{RV}_t)^2}$$

La RMSE pénalise fortement les erreurs importantes. Elle est donc utile pour évaluer la capacité des modèles à éviter de fortes erreurs de prévision, notamment pendant les périodes de stress.

La deuxième métrique est la MAE, ou erreur absolue moyenne :

$$MAE = \frac{1}{N} \sum_{t=1}^N |RV_t - \widehat{RV}_t|$$

La MAE est plus robuste aux grandes erreurs que la RMSE. Elle donne une mesure plus directe de l'erreur moyenne commise par le modèle.

Une troisième métrique pourra être ajoutée si elle est correctement définie : la QLIKE. Cette métrique est souvent utilisée dans l'évaluation des prévisions de volatilité ou de variance, car elle pénalise les écarts relatifs entre la variance réalisée et la variance prédite. Elle peut être formulée de manière générale comme :

$$QLIKE = \frac{1}{N} \sum_{t=1}^N \left(\frac{RV_t^2}{\widehat{RV}_t^2} + \ln(\widehat{RV}_t^2) \right)$$

Dans ce projet, la RMSE et la MAE constitueront les métriques principales, car elles sont simples à interpréter et adaptées à une comparaison pédagogique entre les modèles. La QLIKE pourra être utilisée comme mesure complémentaire si les prévisions sont strictement positives et exprimées dans une unité cohérente.

4.6. Conditions d'une comparaison équitable

Pour que la comparaison entre la baseline naïve, le modèle GARCH(1,1) et le modèle LSTM soit valide, plusieurs conditions doivent être respectées.

Premièrement, les trois modèles doivent chercher à prédire la même variable cible, à savoir la volatilité réalisée future à 10 jours. Deuxièmement, ils doivent être évalués sur la même période de test et sur les mêmes dates. Troisièmement, les prédictions doivent être exprimées dans la même unité que la variable observée, c'est-à-dire en volatilité annualisée.

Quatrièmement, aucun modèle ne doit bénéficier d'une information future indisponible au moment de la prévision. Cela concerne la construction des variables explicatives, la normalisation des données, le découpage temporel et l'alignement des prévisions. Cinquièmement, les hyperparamètres du LSTM ne doivent pas être sélectionnés à partir des performances sur le test final.

Ces conditions permettent d'éviter les comparaisons trompeuses. Un modèle plus complexe, comme le LSTM, ne doit pas être avantagé par une utilisation implicite de l'information future ou par une sélection opportuniste des paramètres. De la même manière, le modèle GARCH doit être converti dans un horizon compatible avec la cible, afin de ne pas comparer des objets statistiques différents.

La comparaison sera donc considérée comme équitable uniquement si elle repose sur une même cible, un même horizon, une même période de test, des métriques identiques et une absence stricte de fuite d'information.

4.7. Reproductibilité du protocole

La reproductibilité constitue un critère important du projet. L'ensemble des étapes devra pouvoir être relancé à partir du notebook Python fourni dans le repository GitHub. Cela concerne le chargement des données, la construction des variables, le découpage temporel, l'estimation des modèles, la production des prévisions, le calcul des métriques et la génération des figures.

Le notebook devra être organisé de manière séquentielle, avec des cellules clairement commentées. Les chemins de fichiers devront être relatifs afin que le projet puisse être exécuté sur un autre ordinateur. Les dépendances Python devront être listées dans un fichier requirements.txt, et les résultats principaux devront être sauvegardés dans un dossier dédié.

Pour le modèle LSTM, les graines aléatoires seront fixées autant que possible afin de limiter la variabilité des résultats liée à l'initialisation des poids et au processus d'optimisation. Il restera toutefois nécessaire de reconnaître que les réseaux de neurones peuvent présenter une certaine variabilité d'un entraînement à l'autre.

Enfin, les résultats présentés dans le rapport devront correspondre aux résultats produits par le notebook. Aucun tableau, graphique ou score ne devra être reporté dans le rapport s'il ne peut pas être retrouvé dans le code. Cette cohérence entre le notebook, le repository GitHub et le rapport final est indispensable pour garantir la transparence du projet.

V. RESULTATS EMPIRIQUES

5.1. Description de la base finale

Après nettoyage des données et construction des variables, la base finale utilisée pour la modélisation contient 5 128 observations journalières. Elle couvre la période allant du 1er février 2005 au 16 décembre 2024. La différence entre la période brute initiale et la période finale s'explique par la construction des variables de volatilité passée et future. En particulier, les premières observations sont perdues lors du calcul des fenêtres mobiles de volatilité passée, tandis que les dernières observations ne peuvent pas être utilisées car la volatilité future à 10 jours n'est pas observable au-delà de la fin de l'échantillon.

La variable de prix utilisée est la colonne Price, interprétée comme le prix journalier de clôture des contrats futures sur le Brent. À partir de cette série, les rendements logarithmiques ont été calculés, puis utilisés pour construire les variables explicatives et la variable cible. La cible du

projet correspond à la volatilité réalisée future à 10 jours, annualisée sur la base de 252 jours de bourse.

Afin de respecter la structure temporelle des données, aucun découpage aléatoire n'a été utilisé. Les observations ont été séparées chronologiquement en trois sous-échantillons : apprentissage, validation et test. Le découpage retenu est présenté dans le tableau suivant.

Table — Chronological data split

Subset	Start date	End date	Number of observations
Train	2005-02-01	2019-01-02	3,589
Validation	2019-01-03	2021-12-23	769
Test	2021-12-24	2024-12-16	770

Le modèle LSTM utilisant des séquences de 30 jours, les premières observations de l'échantillon de test ne peuvent pas être utilisées pour produire une prévision LSTM. Par conséquent, les résultats finaux sont calculés sur une période de test alignée commune aux trois modèles, allant du 3 février 2022 au 16 décembre 2024, soit 741 observations. Cette étape d'alignement garantit que la baseline naïve, le modèle GARCH(1,1) et le modèle LSTM sont évalués exactement sur les mêmes dates.

5.2. Évolution du prix du Brent

Le graphique ci-dessous du prix du Brent permet de visualiser l'évolution de l'actif sur l'ensemble de la période étudiée.

Figure 5.1 : Brent Crude Oil Futures Price




L'évolution du prix met en évidence plusieurs phases de marché distinctes. Certaines périodes sont caractérisées par des mouvements relativement progressifs, tandis que d'autres présentent des ajustements plus brusques. Ces changements de niveau traduisent la sensibilité du Brent aux conditions macroéconomiques, aux tensions sur le marché de l'énergie et aux épisodes de stress financier ou géopolitique. La période dans notre échantillon correspond au début du conflit russo-ukrainien, débuté en février 2022, avec un mouvement assez violent des marchés.

L'analyse du prix en niveau reste toutefois insuffisante pour la prévision de la volatilité. C'est pourquoi la modélisation repose ensuite sur les rendements logarithmiques, qui permettent d'étudier les variations relatives du prix plutôt que son niveau absolu.

5.3. Rendements logarithmiques

Le graphique des rendements logarithmiques journaliers permet d'observer directement l'intensité des variations quotidiennes du prix du Brent.

Figure 5.2 : Daily Log Returns of Brent Crude Oil Futures




Les rendements présentent une alternance entre périodes de faible amplitude et épisodes de fortes variations. Cette structure est typique des séries financières : les chocs importants ne sont pas répartis uniformément dans le temps, mais tendent à se concentrer sur certaines périodes. Ce phénomène correspond au regroupement de la volatilité, selon lequel les périodes agitées tendent à être suivies par d'autres périodes agitées.

Cette observation justifie l'utilisation de modèles de prévision de volatilité. Elle explique également pourquoi une baseline de persistance peut constituer un point de comparaison pertinent, et pourquoi un modèle GARCH peut être adapté à ce type de série.

5.4. Volatilité réalisée

La volatilité réalisée future à 10 jours constitue la variable cible du projet. Elle est calculée à partir des rendements logarithmiques futurs, puis annualisée. Le graphique suivant présente son évolution sur la période étudiée.

Figure 5.3 : Annualized 10-Day Future Realized Volatility of Brent



La série de volatilité réalisée met en évidence plusieurs pics importants. Ces pics correspondent aux périodes durant lesquelles les variations du prix du Brent sont particulièrement fortes. Ils montrent que la volatilité n'est pas constante dans le temps et que sa dynamique peut varier fortement selon les conditions de marché.

Ces variations justifient l'intérêt d'un exercice de prévision. Un bon modèle doit être capable de suivre les changements de régime de volatilité, tout en évitant de réagir excessivement au bruit quotidien. La difficulté principale réside donc dans la capacité à anticiper les hausses de volatilité sans surestimer durablement le risque lorsque le marché se stabilise.

5.5. Performances prédictives des modèles

Les performances finales sont calculées sur le tableau de prédictions alignées, afin que les trois modèles soient évalués sur exactement les mêmes dates. Les métriques retenues sont la RMSE, la MAE et la QLIKE. Les résultats sont présentés dans le tableau suivant.

Table — Final model performance on the aligned test set

Model	RMSE	MAE	QLIKE	RMSE improvement vs naive (%)	MAE improvement vs naive (%)
Naive baseline	0.138458	0.099846	- 1.018300	0.00	0.00

GARCH(1,1)	0.125186	0.089989	- 1.130319	9.59	9.87
LSTM	0.131255	0.090167	- 1.057130	5.20	9.69

Les résultats montrent que les deux modèles avancés améliorent la baseline naïve. Le modèle GARCH(1,1) obtient la meilleure performance globale. Il présente la RMSE la plus faible, avec une amélioration d'environ 9,59 % par rapport à la baseline, ainsi que la MAE la plus faible, avec une amélioration d'environ 9,87 %. Il obtient également la meilleure valeur de QLIKE parmi les trois modèles.


Le LSTM améliore également la baseline naïve, avec une réduction de la RMSE d'environ 5,20 % et une réduction de la MAE d'environ 9,69 %. Toutefois, il ne dépasse pas le modèle GARCH(1,1). L'écart entre le LSTM et le GARCH est relativement faible en MAE, mais plus visible en RMSE. Cela suggère que le LSTM produit des erreurs moyennes proches de celles du GARCH, mais qu'il peut être davantage pénalisé par certaines erreurs importantes.

Ces résultats indiquent donc que, dans le protocole retenu, la flexibilité supplémentaire du LSTM ne se traduit pas par une supériorité nette par rapport au modèle GARCH(1,1). En revanche, le LSTM reste supérieur à la baseline naïve, ce qui montre qu'il apprend une information utile à partir des séquences passées.

5.6. Comparaison visuelle des prévisions

Le graphique ci-joint compare la volatilité réalisée observée et les prévisions produites par les trois modèles sur la période de test alignée.

Figure 5.4 : Forecast Comparison on the Aligned Test Set



Visuellement, les trois modèles suivent globalement la dynamique générale de la volatilité, mais avec des comportements différents. La baseline naïve reproduit mécaniquement la volatilité passée récente. Elle peut donc suivre certains mouvements, mais elle réagit avec retard lorsque la volatilité change rapidement.


Le modèle GARCH(1,1) produit une prévision plus lissée et semble mieux contrôler certaines erreurs moyennes. Sa performance numérique plus favorable suggère qu'il capte efficacement la persistance de la volatilité sur la période de test. Toutefois, comme tout modèle paramétrique, il peut avoir des difficultés à anticiper des pics soudains de volatilité.

Le LSTM produit également une trajectoire relativement lissée. Il semble capable d'exploiter les informations passées, mais ses prévisions ne capturent pas parfaitement les pics extrêmes. Par exemple, la volatilité réalisée atteint un maximum d'environ 1,05 au début du mois de mars 2022, tandis que les prévisions des modèles restent nettement plus basses. Cela illustre la difficulté générale des modèles à prévoir les épisodes de stress très brusques.

5.7. Analyse des erreurs absolues

Le graphique des erreurs absolues permet de comparer les écarts entre la volatilité réalisée et les prévisions de chaque modèle.

Figure 5.5 : Absolute Forecast Errors on the Aligned Test Set



Les erreurs absolues confirment les résultats du tableau de performance. En moyenne, la baseline naïve présente l'erreur absolue la plus élevée, avec une MAE de 0,099846. Le modèle GARCH(1,1) obtient la plus faible MAE, égale à 0,089989, suivi de très près par le LSTM, avec une MAE de 0,090167.

L'écart entre GARCH et LSTM est donc très faible en termes d'erreur absolue moyenne. En revanche, la différence en RMSE indique que le LSTM est davantage pénalisé par certaines erreurs plus importantes. La RMSE du LSTM reste inférieure à celle de la baseline, mais supérieure à celle du GARCH.

Cette analyse montre que le classement des modèles dépend légèrement de la métrique considérée. Selon la MAE, GARCH et LSTM sont très proches. Selon la RMSE et la QLIKE, GARCH apparaît plus nettement comme le meilleur modèle du protocole.

5.8. Synthèse des résultats

Les résultats empiriques conduisent à trois constats principaux.

Premièrement, les deux modèles avancés dépassent la baseline naïve. Cela signifie que GARCH(1,1) et LSTM exploitent une information supplémentaire par rapport à une simple règle de persistance fondée sur la volatilité passée.

Deuxièmement, le modèle GARCH(1,1) obtient les meilleurs résultats globaux sur la période de test alignée. Il présente la meilleure RMSE, la meilleure MAE et la meilleure QLIKE. Dans ce cadre expérimental, il constitue donc le modèle le plus performant.

Troisièmement, le LSTM ne surpasse pas GARCH(1,1), mais il reste compétitif. Sa MAE est très proche de celle du GARCH, ce qui montre qu'il produit des erreurs absolues moyennes similaires. Cependant, sa RMSE plus élevée suggère qu'il est davantage affecté par certaines erreurs importantes, notamment lors des épisodes de forte volatilité.

Il convient donc de ne pas conclure que le LSTM est systématiquement moins pertinent pour la prévision de la volatilité. Les résultats indiquent plutôt que, dans le cadre de ce projet, avec les variables retenues, l'architecture utilisée et la période étudiée, le modèle GARCH(1,1) reste plus performant. Cette conclusion devra être discutée avec prudence, notamment au regard du risque de surapprentissage du LSTM, de la sensibilité aux hyperparamètres et de l'absence de variables macroéconomiques ou géopolitiques dans les données d'entrée.

VI. DISCUSSION CRITIQUE

6.1. Interprétation générale des résultats

Les résultats empiriques montrent que les deux modèles avancés, GARCH(1,1) et LSTM, améliorent la baseline naïve de persistance. Cette observation indique que les modèles exploitent une information dynamique qui n'est pas totalement capturée par la simple hypothèse selon laquelle la volatilité future serait égale à la volatilité récemment observée.

Toutefois, le classement des modèles nuance fortement l'hypothèse initiale du projet. Le modèle LSTM améliore la baseline naïve, mais il ne surpasse pas le modèle GARCH(1,1). Sur la période de test alignée, GARCH obtient les meilleures performances selon les trois métriques retenues : RMSE, MAE et QLIKE. La RMSE du GARCH est égale à 0,125186, contre 0,131255 pour le LSTM et 0,138458 pour la baseline naïve. De même, la MAE du GARCH est égale à 0,089989, contre 0,090167 pour le LSTM et 0,099846 pour la baseline.

Ces résultats suggèrent que, dans le cadre expérimental retenu, la structure simple du GARCH(1,1) reste très compétitive pour la prévision de la volatilité du Brent. Le LSTM apporte bien un gain par rapport à une règle naïve, mais ce gain n'est pas suffisant pour dépasser la référence économétrique.

6.2. Le LSTM apporte-t-il réellement un gain prédictif ?

La réponse à la question de recherche doit être formulée avec prudence. Le LSTM apporte un gain prédictif par rapport à la baseline naïve, mais il n'apporte pas de gain par rapport au modèle GARCH(1,1). En ce sens, l'hypothèse selon laquelle le LSTM pourrait améliorer la prévision de la volatilité future du Brent n'est que partiellement vérifiée.

Par rapport à la baseline naïve, le LSTM réduit la RMSE d'environ 5,20 % et la MAE d'environ 9,69 %. Ces améliorations montrent que le modèle neuronal apprend effectivement une relation utile à partir des séquences de rendements et de volatilité passée. Le LSTM ne se contente donc pas de reproduire mécaniquement la volatilité passée : il exploite une partie de la structure temporelle des données.

Cependant, ce gain doit être relativisé. D'une part, le GARCH(1,1) obtient une amélioration plus forte de la RMSE, avec environ 9,59 % de réduction par rapport à la baseline. D'autre part, la MAE du LSTM est presque identique à celle du GARCH, mais légèrement supérieure. L'écart en MAE entre GARCH et LSTM est très faible, ce qui suggère que les deux modèles produisent des erreurs absolues moyennes proches. En revanche, l'écart en RMSE indique que le LSTM est davantage pénalisé par certaines erreurs importantes.

Ainsi, le LSTM apporte un gain réel par rapport au modèle naïf, mais ce gain reste modéré et ne permet pas de conclure à une supériorité du deep learning dans ce protocole.

6.3. Comportement en période calme et en période de stress

La comparaison des modèles doit également être interprétée en fonction des conditions de marché. Les périodes calmes et les périodes de stress ne posent pas les mêmes difficultés de prévision.

En période relativement stable, les modèles ont tendance à produire des prévisions plus proches de la volatilité réalisée. La baseline naïve peut déjà être compétitive lorsque la volatilité évolue lentement, car la persistance récente constitue une approximation raisonnable du futur proche. Le GARCH bénéficie également de cette persistance, en ajustant progressivement la variance conditionnelle. Le LSTM peut, quant à lui, exploiter les séquences passées pour produire une prévision lissée.

En revanche, lors des épisodes de forte volatilité, la prévision devient nettement plus difficile. Les pics de volatilité sont souvent liés à des événements exogènes soudains, comme des tensions géopolitiques, des annonces macroéconomiques ou des ruptures d'offre et de demande. Ces événements ne sont pas directement observables dans les variables utilisées par le projet, qui reposent uniquement sur les prix et les rendements passés.

Cette limite apparaît notamment dans la difficulté des modèles à anticiper les pics extrêmes. Les modèles peuvent réagir après l'apparition d'un choc, mais ils anticipent difficilement un choc qui n'est pas contenu dans l'historique des rendements. Cette observation concerne particulièrement le LSTM : bien qu'il soit capable de modéliser des dépendances temporelles non linéaires, il ne peut pas apprendre une information absente de ses variables d'entrée.

6.4. Limites liées aux données

La première limite du projet concerne la nature des données utilisées. Les modèles sont entraînés uniquement à partir des prix historiques du Brent et de variables dérivées des rendements. Cette approche permet de construire un protocole clair et reproductible, mais elle limite l'information disponible pour anticiper la volatilité future.

En particulier, le modèle ne dispose pas de variables macroéconomiques, telles que les taux d'intérêt, l'inflation, l'activité industrielle, le taux de change du dollar ou les anticipations de croissance mondiale. Or ces facteurs peuvent influencer fortement le marché pétrolier.

De même, aucune variable géopolitique n'est incluse dans l'analyse. Le Brent est pourtant particulièrement sensible aux tensions internationales, aux décisions de production des pays exportateurs, aux conflits, aux sanctions économiques et aux perturbations logistiques. Ces informations peuvent provoquer des ruptures rapides de volatilité que les seuls rendements passés ne permettent pas nécessairement d'anticiper.

Enfin, l'utilisation d'une seule série financière limite la portée des conclusions. Les résultats obtenus sur le Brent ne peuvent pas être généralisés directement à d'autres matières premières, à d'autres horizons de prévision ou à d'autres périodes de marché.

6.5. Limites du modèle GARCH(1,1)

Le modèle GARCH(1,1) présente l'avantage d'être simple, interprétable et bien adapté à la modélisation de la volatilité conditionnelle. Les résultats empiriques montrent qu'il constitue une référence solide dans ce projet. Toutefois, plusieurs limites doivent être soulignées.

Premièrement, le GARCH(1,1) repose sur une structure paramétrique simple. La variance conditionnelle dépend uniquement du choc passé et de la variance passée. Cette structure permet de capturer la persistance de la volatilité, mais elle peut être insuffisante pour représenter des dynamiques plus complexes, notamment en présence de non-linéarités fortes ou de ruptures de régime.

Deuxièmement, le modèle dépend des hypothèses faites sur les innovations. Dans ce projet, le GARCH standard repose sur une distribution donnée des erreurs. Si les rendements du Brent présentent des queues épaisses ou une asymétrie importante, une spécification plus riche, par exemple avec innovations de Student ou un modèle GJR-GARCH, pourrait être plus adaptée.

Troisièmement, le GARCH ne modélise pas explicitement les facteurs externes. Il peut réagir à une hausse de volatilité une fois que celle-ci est observée dans les rendements, mais il ne peut

pas anticiper directement un choc géopolitique ou macroéconomique non contenu dans l'historique des prix.

6.6. Limites du modèle LSTM

Le LSTM présente une flexibilité supérieure à celle du GARCH, mais cette flexibilité s'accompagne de limites importantes.

La première limite est le risque de surapprentissage. Le LSTM possède un nombre de paramètres plus élevé qu'un modèle GARCH(1,1). Il peut donc apprendre des régularités spécifiques à l'échantillon d'apprentissage qui ne se généralisent pas à la période de test. L'utilisation du dropout et de l'early stopping réduit ce risque, mais ne le supprime pas entièrement.

La deuxième limite est la sensibilité aux hyperparamètres. Les performances du LSTM peuvent dépendre fortement de la longueur des séquences, du nombre d'unités, du taux de dropout, de la taille des batchs, du nombre maximal d'époques et de la méthode de normalisation. Dans ce projet, une architecture volontairement simple a été retenue afin de limiter la complexité, mais d'autres configurations auraient pu produire des résultats différents.

La troisième limite concerne l'interprétabilité. Contrairement au GARCH, dont les paramètres ont une interprétation économétrique claire, le LSTM fonctionne comme un modèle plus opaque. Il est plus difficile d'identifier précisément quelles variables ou quelles observations passées expliquent une prévision donnée. Cette limite est importante dans un contexte financier, où l'explicabilité des modèles peut être aussi importante que leur performance prédictive.

Enfin, le LSTM ne peut apprendre que des informations présentes dans les données d'entrée. Dans ce projet, les variables utilisées sont dérivées des rendements passés. Si les hausses de volatilité sont déclenchées par des événements externes non observés, le LSTM ne dispose pas de l'information nécessaire pour les anticiper.

6.7. Robustesse des résultats

Les résultats doivent être interprétés comme dépendants du protocole expérimental retenu. La comparaison repose sur une période de test spécifique, allant du 3 février 2022 au 16 décembre 2024 après alignement des prédictions. Cette période inclut des épisodes de tension sur le marché de l'énergie, ce qui peut influencer le classement des modèles.

La robustesse des conclusions pourrait être renforcée par plusieurs extensions. Premièrement, il serait utile de tester d'autres longueurs de séquences pour le LSTM, par exemple 20, 60 ou 90 jours. Deuxièmement, on pourrait comparer plusieurs architectures LSTM, tout en évitant une sélection opportuniste des hyperparamètres. Troisièmement, une validation glissante ou une évaluation sur plusieurs fenêtres temporelles permettrait de vérifier si le classement des modèles reste stable selon la période considérée.

La robustesse du modèle GARCH pourrait également être testée en modifiant la distribution des innovations ou en utilisant des variantes telles que EGARCH ou GJR-GARCH. Ces

modèles permettent de prendre en compte certains effets asymétriques ou des dynamiques plus flexibles de la volatilité.

En l'état, les résultats montrent que GARCH domine le LSTM sur la période étudiée, mais ils ne permettent pas d'affirmer que GARCH serait toujours supérieur dans tout contexte ou sur tout actif.

6.8. Prudence sur la généralisation

La conclusion principale du projet doit rester limitée au cadre empirique étudié. Les résultats ne démontrent pas une supériorité générale du GARCH sur les LSTM, ni une inefficacité générale du deep learning pour la prévision de volatilité. Ils montrent plutôt que, dans ce projet, avec les données retenues, les variables construites, l'horizon de 10 jours et l'architecture LSTM utilisée, le GARCH(1,1) obtient les meilleurs résultats.

Cette prudence est importante pour éviter une surinterprétation. Le LSTM pourrait obtenir de meilleures performances avec d'autres variables d'entrée, par exemple des indicateurs macroéconomiques, des mesures de sentiment de marché, des données de volatilité implicite ou des informations géopolitiques structurées. Il pourrait également être plus performant sur d'autres horizons ou avec une stratégie d'entraînement plus avancée.

La portée des résultats est donc empirique et conditionnelle. Le projet permet de comparer rigoureusement trois approches dans un cadre donné, mais il ne permet pas de conclure définitivement sur la supériorité d'une famille de modèles.

6.9. Synthèse de la discussion

La discussion critique conduit à une conclusion nuancée. Le LSTM apporte une amélioration par rapport à la baseline naïve, ce qui montre qu'il apprend une information utile à partir des séquences passées. Toutefois, cette amélioration reste modérée et ne suffit pas à dépasser le modèle GARCH(1,1). Le GARCH conserve les meilleures performances globales, probablement parce que la volatilité du Brent présente une forte persistance que ce modèle capture efficacement.

Le principal enseignement du projet est donc méthodologique : la complexité d'un modèle ne garantit pas nécessairement une meilleure performance prédictive. Dans un contexte de séries financières, un modèle simple, bien adapté à la structure statistique de la variable étudiée, peut rester très compétitif face à un modèle de deep learning.

Cette conclusion renforce l'importance d'inclure des benchmarks solides dans tout projet de machine learning appliqué à la finance. Sans baseline naïve et sans modèle GARCH, il aurait été difficile d'évaluer correctement la valeur ajoutée réelle du LSTM.

VII. CONCLUSION

L'objectif de ce projet était d'évaluer la capacité d'un modèle LSTM à prévoir la volatilité réalisée future du Brent Crude Oil, et de comparer ses performances à celles d'un modèle économétrique classique, le GARCH(1,1), ainsi qu'à une baseline naïve de persistance. La question de recherche était la suivante :

Un modèle LSTM permet-il de prévoir plus précisément la volatilité réalisée future à 10 jours du Brent qu'un modèle GARCH(1,1) et qu'une baseline naïve ?

Pour répondre à cette question, nous avons construit un protocole empirique fondé sur des données journalières de contrats futures sur le Brent, couvrant la période allant de 2005 à 2024. À partir des prix de clôture, nous avons calculé les rendements logarithmiques journaliers, puis construit une variable cible correspondant à la volatilité réalisée future à 10 jours, annualisée sur la base de 252 jours de bourse. Les variables explicatives utilisées par le LSTM incluent notamment les rendements logarithmiques, les rendements absolus, les rendements au carré ainsi que des mesures de volatilité réalisée passée.

Le protocole a été conçu afin de respecter la structure temporelle des données. Les observations ont été divisées chronologiquement en un échantillon d'apprentissage, un échantillon de validation et un échantillon de test. Aucun découpage aléatoire n'a été utilisé. Les modèles ont ensuite été évalués sur une période de test commune, après alignement des prédictions, à l'aide de trois métriques principales : la RMSE, la MAE et la QLIKE.

Les résultats empiriques montrent que le LSTM apporte un gain prédictif par rapport à la baseline naïve. Il réduit la RMSE d'environ 5,20 % et la MAE d'environ 9,69 % par rapport à cette règle simple de persistance. Ce résultat indique que le LSTM parvient à exploiter une partie de l'information contenue dans les séquences passées de rendements et de volatilité.

Cependant, le LSTM ne surpasse pas le modèle GARCH(1,1). Le GARCH obtient les meilleures performances globales, avec une RMSE de 0,125186, une MAE de 0,089989 et la meilleure valeur de QLIKE. Il améliore la baseline naïve d'environ 9,59 % selon la RMSE et 9,87 % selon la MAE. Dans le cadre de ce projet, le modèle le plus performant est donc le GARCH(1,1).

La réponse empirique à la question de recherche est donc nuancée. Le LSTM permet bien d'améliorer la prévision par rapport à une baseline naïve, mais il ne permet pas de prévoir plus précisément la volatilité réalisée future à 10 jours du Brent que le modèle GARCH(1,1). La flexibilité supplémentaire du modèle neuronal ne se traduit donc pas, dans ce protocole, par une supériorité prédictive nette.

Plusieurs limites doivent toutefois être rappelées. Premièrement, les modèles utilisent uniquement des données historiques de prix et de rendements. Ils ne prennent pas en compte de variables macroéconomiques, telles que les taux d'intérêt, l'inflation, le taux de change du dollar ou les indicateurs d'activité mondiale. Deuxièmement, aucune variable géopolitique n'est intégrée, alors que le marché du pétrole est fortement exposé aux tensions internationales,

aux décisions de production et aux chocs d'offre. Troisièmement, les résultats dépendent de la période étudiée, de l'horizon de prévision retenu et des choix d'hyperparamètres du LSTM.

Nonobstant des résultats convaincants, plusieurs pistes d'amélioration peuvent être envisagées. Une première extension consisterait à enrichir les variables explicatives avec des données macroéconomiques ou financières externes. Une deuxième piste serait de tester d'autres horizons de prévision, par exemple 5, 20 ou 30 jours, afin d'évaluer si le classement des modèles varie selon l'horizon. Une troisième amélioration consisterait à appliquer le même protocole à d'autres actifs énergétiques, comme le WTI ou le gaz naturel. Il serait également pertinent de comparer le LSTM à d'autres modèles, tels que EGARCH, GJR-GARCH, Random Forest, XGBoost ou GRU. Enfin, l'utilisation d'une validation glissante permettrait de tester la stabilité des performances dans le temps.

En définitive, ce projet montre que la complexité d'un modèle ne garantit pas nécessairement une meilleure performance prédictive. Dans le cas étudié, un modèle économétrique simple et bien adapté à la dynamique de la volatilité, le GARCH(1,1), reste plus performant que le LSTM. Le principal enseignement méthodologique est donc l'importance de comparer tout modèle de machine learning à des benchmarks solides avant de conclure à sa valeur ajoutée.

BIBLIOGRAPHIE & ANNEXES

GITHUB REPOSITORY: <https://github.com/baptiste-dehay/brent-volatility-lstm-garch/tree/main>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). *Scikit-learn: Machine learning in Python*. **Journal of Machine Learning Research**, 12, 2825–2830.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Kingma, D. P., & Ba, J. (2015). *Adam: A method for stochastic optimization*. International Conference on Learning Representations.

Patton, A. J. (2011). *Volatility forecast comparison using imperfect volatility proxies*. **Journal of Econometrics**, 160(1), 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>

Andersen, T. G., Bollerslev, T., Diebold, F. X., & Labys, P. (2003). *Modeling and forecasting realized volatility*. **Econometrica**, 71(2), 579–625. <https://doi.org/10.1111/1468-0262.00418>

Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. **Neural Computation**, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>

Bollerslev, T. (1986). *Generalized autoregressive conditional heteroskedasticity*. **Journal of Econometrics**, 31(3), 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)

Engle, R. F. (1982). *Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation*. **Econometrica**, **50**(4), 987–1007.
<https://doi.org/10.2307/1912773>